

Aumento de datos sintéticos con modelos generativos para mitigar el desbalanceo de clases en la detección de melanoma dermoscópico

Santiago Chica, Gabriel Gómez, Michael Patiño, Juan Diego Sarmiento

Resumen—El desbalanceo de clases es un obstáculo central en la clasificación de imágenes dermatológicas: patologías como el melanoma están escasamente representadas en los conjuntos de datos disponibles, lo que limita la sensibilidad de los modelos sobre la clase minoritaria. En este trabajo se evalúa el aumento de datos sintéticos como estrategia de rebalanceo, comparando cuatro métodos generativos: Textual Inversion, LoRA y Derm-T2IM sobre Stable Diffusion v1.5, y WGAN-GP. Utilizamos el conjunto HAM10000 para clasificación binaria nevus/melanoma como conjunto de datos para hacer la evaluación de los métodos generativos. Cada generador aporta 801 imágenes sintéticas de melanoma en escenarios híbridos (real + sintético) y exclusivamente sintético. Un clasificador EfficientNet-B0 se evalúa en todos los casos sobre un conjunto de prueba 100 % real.

El aumento de datos híbrido mejora el AUC del baseline (0.911) en todos los generadores, con WGAN-GP alcanzando 0.929 y Derm-T2IM $s = 0,05$ registrando el mayor incremento en recall (+8.2 pp). El entrenamiento exclusivamente con sintéticas colapsa en tres de los cuatro métodos (Recall ≈ 0), mientras que Derm-T2IM con perturbación mínima mantiene viabilidad (AUC=0.878). Los resultados indican que el domain shift entre imágenes sintéticas y reales es el factor determinante en la transferibilidad del clasificador, más que el método generativo en sí.

Index Terms—melanoma, HAM10000, desbalanceo de clases, aumento de datos sintéticos, Stable Diffusion, modelos generativos, clasificación dermatológica

I. INTRODUCCIÓN

EL avance de las redes neuronales convolucionales ha impulsado el desarrollo de sistemas de diagnóstico dermatológico asistido con desempeño comparable al de especialistas clínicos en tareas de clasificación de imágenes [1]. El melanoma concentra gran parte de este interés: su alta capacidad metastásica contrasta con pronósticos favorables cuando se detecta de forma temprana, lo que convierte su detección automática en una herramienta de alto impacto, especialmente en regiones con acceso limitado a dermatólogos especializados. No obstante, el entrenamiento de modelos robustos exige grandes volúmenes de datos correctamente etiquetados y equilibrados entre clases diagnósticas, una condición que los conjuntos médicos disponibles rara vez satisfacen.

El principal obstáculo es el marcado desbalanceo de clases. HAM10000 [5] contiene 10015 imágenes dermoscópicas distribuidas en siete categorías; al filtrar el subconjunto binario nevus/melanoma utilizado en este trabajo se obtienen 7818 imágenes, de las cuales el 85.8 % corresponden a nevus

(6705) y apenas el 14.2 % a melanoma (1113). Esta asimetría induce un sesgo sistemático hacia la clase mayoritaria, reduciendo la sensibilidad del modelo sobre las lesiones malignas que son las más críticas de detectar [13].

Las técnicas de aumento de datos convencionales (rotaciones, volteos, modificaciones de contraste, filtros) incrementan el recuento de muestras sin introducir variabilidad morfológica ni semántica nueva. Los modelos generativos profundos ofrecen una alternativa más rica: tanto las redes generativas antagónicas (GANs) [4] como los modelos de difusión probabilística [15] pueden sintetizar imágenes con diversidad estructural controlada. Stable Diffusion [15], en particular, habilita estrategias de ajuste fino orientadas a clases específicas: textual inversion [6], LoRA [7] y variantes dermoscópicas especializadas, que permiten generar muestras condicionadas por patología sin reentrenar el modelo completo.

La utilidad de los datos sintéticos, sin embargo, no está garantizada por su realismo visual. Una imagen visualmente convincente puede introducir domain shift suficiente como para degradar el rendimiento del clasificador. Esto exige una evaluación en dos niveles: métricas estadísticas de distribución como Fréchet Inception Distance (FID) [16] e Inception Score (IS) [18] para cuantificar la calidad generativa, y validación directa sobre tareas de clasificación con conjuntos de prueba exclusivamente reales para medir el impacto efectivo [10].

En este trabajo se evalúa sistemáticamente el aumento de datos sintéticos como estrategia de rebalanceo para clasificación binaria nevus/melanoma sobre HAM10000. El conjunto se particiona de forma estratificada por identificador de lesión (70/15/15): 5476 imágenes de entrenamiento (801 mel / 4675 nv), 1171 de validación (153 mel / 1018 nv) y 1171 de prueba (159 mel / 1012 nv). Se comparan cuatro métodos generativos: Textual Inversion [6], LoRA [7], Derm-T2IM [8] y WGAN-GP [9], bajo un protocolo de volumen fijo de 801 imágenes sintéticas de melanoma por generador, igualando la cantidad de melanomas reales disponibles en entrenamiento. Un clasificador EfficientNet-B0 se evalúa en once escenarios: baseline real, cinco configuraciones híbridas (real + sintético, 2x) y cinco exclusivamente sintéticas. El conjunto de prueba es siempre 100 % real.

Las principales contribuciones de este trabajo son:

- Comparación controlada de cuatro estrategias generativas: Textual Inversion, LoRA, Derm-T2IM y WGAN-GP, manteniendo volumen de aumento constante (801 imágenes por generador) para hacer comparables los resultados entre métodos.

- Evaluación en escenarios híbridos y exclusivamente sintéticos con test set 100 % real, midiendo el impacto sobre la clase minoritaria con AUC-ROC, Recall y F1-score de melanoma.
- Análisis de la calidad generativa mediante FID e IS, y su relación con el rendimiento del clasificador en cada escenario.
- Evidencia de que el domain shift (medido por FID) determina si el entrenamiento exclusivamente sintético es viable: el único generador que evita el colapso del clasificador es Derm-T2IM, que produce imágenes con menor distancia a la distribución real (FID=21.1).

El resto del documento se organiza así: la Sección II revisa el estado del arte, la Sección III describe los materiales, la Sección IV detalla la metodología, la Sección V presenta los resultados, la Sección VI discute los hallazgos y limitaciones, y la Sección VII recoge las conclusiones.

II. ESTADO DEL ARTE

II-A. Clasificación de lesiones cutáneas con aprendizaje profundo

El uso de redes neuronales convolucionales para el diagnóstico dermatológico asistido tomó impulso con el trabajo de Esteva et al. [1], que demostró que una CNN entrenada sobre 129450 imágenes clínicas alcanza un desempeño comparable al de dermatólogos certificados en la distinción entre melanoma maligno y nevos benignos. Desde entonces, arquitecturas más eficientes como EfficientNet [2] se han consolidado como estándar en tareas de clasificación de imágenes médicas gracias a su escalado compuesto de profundidad, ancho y resolución. Sobre HAM10000, modelos preentrenados en ImageNet y ajustados sobre datos dermatoscópicos alcanzan regularmente AUC superiores a 0.90 en la tarea binaria nevus/melanoma, estableciendo la línea base sobre la que se mide el beneficio de cualquier estrategia de rebalanceo.

II-B. El problema del desbalanceo de clases

El principal obstáculo en la clasificación dermatológica no es la arquitectura del modelo sino la distribución asimétrica de los datos. En HAM10000, la clase mayoritaria (nevus) representa el 67 % del dataset completo y el 85.8 % del subconjunto binario nevus/melanoma. Un clasificador que ignora este desbalanceo tiende a optimizar la exactitud global prediciendo siempre la clase mayoritaria, lo que resulta en sensibilidad reducida sobre las lesiones malignas.

Las estrategias más utilizadas para mitigar este problema son el sobremuestreo de la clase minoritaria y el submuestreo de la mayoritaria. SMOTE [3] genera muestras sintéticas interpolando en el espacio de características entre ejemplos reales de la clase minoritaria, y sigue siendo una de las técnicas más citadas. Sin embargo, en imágenes de alta dimensionalidad la interpolación en el espacio de píxeles produce artefactos visuales que no corresponden a variaciones morfológicas reales, limitando su utilidad en imágenes médicas. Las técnicas de coste sensible, que penalizan más los errores sobre la clase minoritaria, ofrecen una alternativa sin modificar los datos, pero no aportan diversidad morfológica al conjunto de entrenamiento.

II-C. GANs para síntesis de imágenes médicas

Las redes generativas antagónicas abrieron la posibilidad de generar imágenes sintéticas con diversidad estructural controlada. En dermatoscopia, Baur et al. [4] proponen MelanoGANs, un sistema basado en GANs de alta resolución para sintetizar imágenes de melanoma, y demuestran que las muestras generadas son suficientemente realistas para ser indistinguibles de las reales en evaluaciones ciegas. No obstante, las GANs convencionales son propensas a inestabilidad durante el entrenamiento y al fenómeno de *mode collapse*, en el que el generador produce una variedad limitada de imágenes. WGAN-GP [9] resuelve parte de estos problemas reemplazando el recorte de pesos del discriminador por una penalización de gradiente que estabiliza el entrenamiento sin restringir la capacidad representacional del modelo.

II-D. Modelos de difusión y estrategias de ajuste fino

Los modelos de difusión latente, y en particular Stable Diffusion [15], superaron a las GANs en estabilidad de entrenamiento y calidad visual, al mismo tiempo que permiten generación condicionada por texto. Su arquitectura latente reduce el costo computacional al operar en un espacio comprimido en lugar de sobre los píxeles directamente.

Sobre este modelo base se han desarrollado distintas estrategias de ajuste fino para clases específicas. Gal et al. [6] proponen Textual Inversion, que aprende un nuevo token textual capaz de representar un concepto visual a partir de pocas imágenes de referencia, sin modificar los pesos del modelo. Ruiz et al. [7] proponen DreamBooth, que ajusta el modelo completo asociando un identificador único con la clase objetivo e incorpora una pérdida de preservación de prior para evitar el olvido catastrófico. Su variante con LoRA (*Low-Rank Adaptation*) reduce el costo computacional adaptando únicamente matrices de bajo rango en las capas de atención, sin necesidad de modificar todos los parámetros del modelo.

Farooq et al. [8] presentan Derm-T2IM, un modelo Stable Diffusion ajustado específicamente sobre imágenes dermatoscópicas de HAM10000 e ISIC. A diferencia de los métodos anteriores, opera en modo imagen-a-imagen: toma una imagen real de melanoma como referencia y genera variaciones de ella mediante un parámetro de fuerza que controla el grado de modificación. Al estar ajustado sobre el mismo dominio dermatoscópico, produce imágenes con distribución más cercana a los datos reales que los modelos de propósito general.

II-E. Aumento de datos sintéticos en clasificación dermatológica

Varios trabajos han evaluado el impacto de los datos sintéticos en clasificadores entrenados sobre HAM10000. Akrouit et al. [10] comparan clasificadores entrenados con proporciones crecientes de imágenes generadas por Stable Diffusion y concluyen que los conjuntos híbridos (real + sintético) mantienen desempeño competitivo frente al entrenamiento completamente real, mientras que el entrenamiento exclusivamente sintético degrada los resultados. Este trabajo constituye el antecedente más directo del presente estudio, pero no compara múltiples métodos generativos bajo un protocolo de volumen controlado.

En un contexto más amplio, Ibrahim et al. [13] analizan el uso de IA generativa en múltiples modalidades clínicas y reportan mejoras consistentes en la detección de patologías poco representadas cuando se incorporan datos sintéticos. Chan et al. [12] ofrecen una revisión comparativa de VAEs, GANs y modelos de difusión, destacando que la generación sintética aporta diversidad más allá del simple incremento de volumen. Rahat et al. [11] y Zhang et al. [14] refuerzan esta línea mostrando que los datos sintéticos son especialmente valiosos cuando la cantidad de datos reales es limitada, ya sea por escasez de anotaciones o por la rareza de la condición clínica.

II-F. Métricas de evaluación generativa

La evaluación de la calidad de imágenes sintéticas se apoya en dos métricas estándar. El Fréchet Inception Distance (FID) [16] compara las distribuciones de imágenes reales y generadas en el espacio de activaciones de Inception v3: valores menores indican menor distancia distribucional y, en consecuencia, mayor similitud estadística con los datos reales. El Inception Score (IS) [18] mide simultáneamente calidad y diversidad mediante la distribución de predicciones de un clasificador sobre las imágenes generadas, aunque resulta menos sensible que el FID para detectar *domain shift* o *mode collapse* en datasets especializados.

A diferencia de los trabajos anteriores, este estudio compara cuatro métodos generativos de forma controlada (volumen fijo, mismo clasificador, mismo test set exclusivamente real) sobre la tarea binaria nevus/melanoma en HAM10000, evaluando tanto calidad generativa como impacto directo en clasificación en escenarios híbridos y exclusivamente sintéticos.

III. MATERIALES

III-A. Dataset HAM10000

El dataset utilizado es HAM10000 (Human Against Machine with 10000 training images) [5], un conjunto de datos dermatológicos compuesto por 10 015 imágenes dermatoscópicas RGB de lesiones cutáneas pertenecientes a siete categorías diagnósticas. Las imágenes tienen una resolución aproximada de 600×450 píxeles y provienen de distintas fuentes clínicas, lo que introduce variaciones en iluminación, contraste y condiciones de adquisición.

Para este trabajo se define una tarea de clasificación binaria entre nevos melanocíticos (*nv*) y melanoma (*mel*), descartando las otras cinco categorías del dataset original. El subconjunto resultante contiene 7 818 imágenes: 6 705 nevos (85.8 %) y 1 113 melanomas (14.2 %).

El dataset incluye múltiples imágenes de una misma lesión, lo que puede introducir *data leakage* si la partición se hace por imagen. Por esta razón, la división se realiza a nivel de identificador de lesión (*lesion_id*), garantizando que todas las imágenes de una misma lesión pertenezcan al mismo subconjunto. La partición estratificada (70/15/15) produce: 5 476 imágenes de entrenamiento (801 *mel* / 4 675 *nv*), 1 171 de validación (153 *mel* / 1 018 *nv*) y 1 171 de prueba (159 *mel* / 1 012 *nv*).

III-B. Herramientas y entorno computacional

La implementación se desarrolla en Python con PyTorch como framework de aprendizaje profundo. Para la generación de imágenes sintéticas se emplea la librería Hugging Face Diffusers con el modelo base `runwayml/stable-diffusion-v1-5`. El clasificador se implementa con EfficientNet-B0 preentrenado en ImageNet, disponible en `torchvision`. Las métricas FID e IS se calculan con `torch-fidelity`.

El entrenamiento de los generadores y del clasificador se ejecuta en Google Colab con GPU NVIDIA L4 (24 GB VRAM).

IV. MÉTODOS

La metodología se organiza en tres etapas: generación de imágenes sintéticas de melanoma, validación de calidad generativa y entrenamiento de clasificadores bajo distintos escenarios experimentales.

IV-A. Generación de imágenes sintéticas

Se implementan cuatro métodos de generación orientados a producir imágenes de melanoma para el aumento de datos de la clase minoritaria.

IV-A1. Textual Inversion: Textual Inversion [6] permite personalizar un modelo de texto a imagen preentrenado para representar un concepto visual específico sin modificar los pesos del modelo base. El proceso aprende un nuevo token textual en el espacio de embeddings, de forma que ese token capture las características visuales del concepto a partir de un conjunto pequeño de imágenes de referencia. Una vez obtenido el token, puede integrarse en cualquier prompt para guiar la generación de nuevas imágenes del concepto en distintos contextos.

En este trabajo se entrena el token `<mel-skin>` sobre las 801 imágenes de melanoma del conjunto de entrenamiento durante 5 000 pasos, con el modelo `runwayml/stable-diffusion-v1-5` completamente congelado. Se generan 4 500 imágenes usando el prompt *“dermoscopy image of <mel-skin>, skin lesion, clinical photography, high quality”*.

IV-A2. WGAN-GP: WGAN-GP [9] es una variante de las GANs que mejora la estabilidad del entrenamiento. El discriminador aprende a distinguir imágenes reales de generadas maximizando la distancia de Wasserstein entre ambas distribuciones. Para que el entrenamiento sea estable, se añade una penalización que obliga al discriminador a cambiar suavemente en cualquier punto del espacio de imágenes:

$$\mathcal{L} = \underbrace{\mathbb{E}[D(\hat{x})] - \mathbb{E}[D(x)]}_{\text{distancia Wasserstein}} + \lambda \mathbb{E}_{\hat{x}} \left[\left(\|\nabla_{\hat{x}} D(\hat{x})\|_2 - 1 \right)^2 \right] \quad (1)$$

donde x son imágenes reales, $\hat{x}$ son imágenes generadas, $\hat{x}$ son interpolaciones entre ambas y λ pondera la penalización. El resultado es un entrenamiento más estable y con menor tendencia al *mode collapse* que las GANs convencionales.

A diferencia de los métodos basados en Stable Diffusion, WGAN-GP se entrena desde cero sobre las imágenes de

melanoma del conjunto de entrenamiento. El entrenamiento se realiza durante 100 épocas con resolución de salida 64×64 píxeles, siguiendo una arquitectura convolucional estándar para generador y discriminador. Se generan 5 000 imágenes a partir del generador final.

IV-A3. DreamBooth con LoRA: DreamBooth [7] realiza un ajuste fino del modelo de difusión para asociar un identificador único con la apariencia de una clase específica. A diferencia de Textual Inversion, que solo aprende el embedding textual, DreamBooth modifica los pesos del modelo e incorpora una pérdida de preservación de prior para evitar que el modelo olvide la distribución general de imágenes durante el ajuste fino.

Para reducir el costo computacional se emplea la variante con LoRA (*Low-Rank Adaptation*), que reemplaza las actualizaciones de peso completas por matrices de bajo rango ($r = 32$) en las capas de atención. El ajuste fino se realiza sobre las imágenes de melanoma del conjunto de entrenamiento con el modelo `runwayml/stable-diffusion-v1-5` como base, produciendo 4 501 imágenes sintéticas.

IV-A4. Derm-T2IM: Derm-T2IM [8] es un modelo Stable Diffusion ajustado específicamente sobre imágenes dermatoscópicas de HAM10000 e ISIC. A diferencia de los métodos anteriores, no requiere ajuste fino adicional: se utiliza directamente en modo imagen-a-imagen, donde una imagen real de melanoma sirve de referencia y el modelo genera variaciones de ella.

El grado de modificación se controla con el parámetro de fuerza $s \in [0, 1]$: valores altos producen variaciones más diversas, mientras que valores bajos generan perturbaciones mínimas que conservan la estructura de la imagen original. Se evalúan dos configuraciones: $s = 0,40$, orientada a producir mayor variación morfológica y diversidad clínica, y $s = 0,05$, que introduce perturbaciones mínimas para maximizar la fidelidad a la imagen original y minimizar el domain shift. Ambos valores se evalúan en escenarios híbridos y exclusivamente sintéticos, resultando en cuatro escenarios Derm-T2IM. Cada configuración produce 1 602 imágenes (dos variaciones por cada imagen de melanoma del conjunto de entrenamiento).

Tabla I
RESUMEN DE MÉTODOS GENERATIVOS. FID E IS CALCULADOS RESPECTO AL CONJUNTO DE MELANOMAS REALES DE ENTRENAMIENTO. COMPLEJIDAD BASADA EN PARÁMETROS ENTRENABLES Y REQUISITOS DE GPU.

Método	N	FID	IS	Complejidad
Textual Inversion	4 500	272.9	3.37	Baja
WGAN-GP	5 000	220.8	3.37	Media
DreamBooth + LoRA	4 501	121.7	3.43	Media-Alta
Derm-T2IM $s = 0,40$	1 602	46.7	3.43	Baja
Derm-T2IM $s = 0,05$	1 602	21.1	3.43	Baja

IV-B. Validación de imágenes sintéticas

La calidad del conjunto resultante se evalúa con FID [16] e IS [18]. El FID compara las distribuciones de imágenes reales y sintéticas en el espacio de activaciones de Inception v3:

$$\text{FID} = \|\mu_r - \mu_g\|^2 + \text{Tr}(\Sigma_r + \Sigma_g - 2(\Sigma_r \Sigma_g)^{1/2}) \quad (2)$$

donde μ_r , Σ_r y μ_g , Σ_g son las medias y covarianzas de las activaciones sobre imágenes reales y generadas, respectivamente; valores menores indican menor distancia distribucional. El IS cuantifica simultáneamente calidad y diversidad:

$$\text{IS} = \exp(\mathbb{E}_x[\text{KL}(p(y|x) \| p(y))]) \quad (3)$$

donde $p(y|x)$ es la distribución de clase predicha por Inception v3 para la imagen x y $p(y) = \int p(y|x) dp(x)$ es la distribución marginal. En este experimento los valores de IS son similares entre métodos (rango 3.37–3.43), por lo que el FID es la métrica discriminante.

IV-C. Entrenamiento de clasificadores

Se entrena un clasificador EfficientNet-B0 [2] con pesos preentrenados en ImageNet, reemplazando la cabeza de clasificación por una capa densa de dos neuronas (nevus / melanoma). Se utiliza el optimizador AdamW con tasa de aprendizaje 1×10^{-4} , *weight decay* 1×10^{-4} y planificador CosineAnnealingLR durante 15 épocas. Las imágenes se redimensionan a 224×224 píxeles y se normalizan con la media y desviación estándar de ImageNet. El aumento de datos estándar incluye volteo horizontal y vertical, rotación aleatoria de ± 20 y ajuste de color (ColorJitter). El modelo se guarda en el punto de menor pérdida de validación.

Las métricas de evaluación principal son Recall, Precisión y F1-score de la clase melanoma, junto con el AUC-ROC:

$$\text{Recall} = \frac{TP}{TP + FN}, \quad \text{Precisión} = \frac{TP}{TP + FP} \quad (4)$$

$$\text{F1} = \frac{2 \cdot \text{Precisión} \cdot \text{Recall}}{\text{Precisión} + \text{Recall}} \quad (5)$$

$$\text{AUC} = \int_0^1 \text{TPR}(\text{FPR}^{-1}(t)) dt \quad (6)$$

donde TP , FP , FN y TN son verdaderos positivos, falsos positivos, falsos negativos y verdaderos negativos de la clase melanoma; $\text{TPR} = \text{Recall}$ y $\text{FPR} = \text{FP}/(\text{FP} + \text{TN})$. El Recall recibe énfasis especial dado que la detección de melanomas no diagnosticados tiene mayor coste clínico que los falsos positivos.

El desbalanceo de clases se aborda exclusivamente mediante el aumento de datos sintéticos, sin recurrir a técnicas de balanceo paramétrico, de modo que el efecto de los datos generados pueda evaluarse de forma aislada.

Se definen nueve escenarios en tres grupos:

- **Baseline:** entrenamiento con datos reales únicamente (801 mel / 4 675 nv).
- **Híbrido 2x:** 801 imágenes reales de melanoma más 801 sintéticas por generador (TI, LoRA, GAN, Derm $s = 0,40$, Derm $s = 0,05$).
- **Solo sintéticas:** 801 imágenes sintéticas sin datos reales de melanoma (TI, LoRA, GAN, Derm $s = 0,05$, Derm $s = 0,40$).

En todos los escenarios el conjunto de validación y prueba es 100 % real.




Figura 1. Muestras representativas (2×3) de cada generador. WGAN-GP produce lesiones visualmente reconocibles pero con resolución limitada a 64×64 píxeles. DreamBooth + LoRA genera imágenes de mayor resolución con morfología dermatoscópica consistente. Las dos configuraciones de Derm-T2IM ($s = 0,40$ y $s = 0,05$) se ven similares entre sí porque ambas parten de imágenes reales de melanoma y aplican el modelo sobre dominio dermatoscópico: la diferencia está en el grado de perturbación ($s = 0,05$ introduce cambios mínimos, casi imperceptibles; $s = 0,40$ introduce mayor variación estructural), lo que se refleja en sus FID de 21.1 y 46.7 respectivamente. Textual Inversion produce patrones que no corresponden a estructuras dermatoscópicas, lo que explica su FID de 272.9 y el colapso del clasificador en entrenamiento exclusivamente sintético.

V. RESULTADOS

V-A. Calidad generativa

La Fig. 1 muestra muestras representativas de cada generador. Las diferencias visuales son notorias: Textual Inversion produce patrones abstractos sin estructura dermatoscópica, mientras que Derm-T2IM genera imágenes indistinguibles de los melanomas reales de referencia.

Los valores de FID e IS para cada método se presentan en la Tabla I. El FID varía ampliamente entre métodos, desde 272.9 (Textual Inversion) hasta 21.1 (Derm-T2IM $s = 0,05$), lo que refleja diferencias significativas en la proximidad distribucional respecto a los melanomas reales de entrenamiento. El IS presenta valores similares en todos los métodos (rango 3.37–3.43), confirmando que no discrimina entre generadores en este contexto.

V-B. Clasificación

La Tabla II presenta los resultados de los escenarios baseline e híbridos. Todos los generadores mejoran el AUC del baseline (0.911) al incorporar datos sintéticos. WGAN-GP alcanza el mayor AUC (0.929), Derm-T2IM $s = 0,05$ registra el mayor Recall (0.610, +8.2pp sobre el baseline) y LoRA obtiene la mayor precisión (0.703). Ambas configuraciones de Derm-T2IM obtienen resultados similares en el escenario híbrido (AUC 0.917 y 0.920; Recall 0.604 y 0.610), lo que indica que en presencia de datos reales el parámetro s tiene un efecto marginal sobre el rendimiento del clasificador.

La Tabla III muestra los resultados de los escenarios exclusivamente sintéticos. TI, LoRA y GAN colapsan: el clasificador

Tabla II
RESULTADOS EN ESCENARIOS BASELINE E HÍBRIDOS (TEST SET 100 % REAL). EN NEGRITA EL MEJOR VALOR POR COLUMNA.

Escenario	AUC	Recall	Prec.	F1	Acc.
Baseline	0.911	0.528	0.641	0.579	0.896
Híbrido TI	0.920	0.585	0.650	0.616	0.901
Híbrido LoRA	0.926	0.535	0.703	0.607	0.906
Híbrido GAN	0.929	0.579	0.635	0.605	0.898
Híbrido Derm $s = 0,40$	0.917	0.604	0.568	0.585	0.884
Híbrido Derm $s = 0,05$	0.920	0.610	0.618	0.614	0.896

no detecta melanomas (Recall ≈ 0) y el AUC cae a valores cercanos al azar (0.55–0.61). Las dos configuraciones de Derm-T2IM se diferencian notablemente: $s = 0,40$ evita el colapso total (AUC = 0.845) pero obtiene un Recall bajo (0.145), mientras que $s = 0,05$ mantiene viabilidad plena (AUC = 0.878, Recall = 0.478). Esta diferencia es coherente con sus FID respectivos (46.7 frente a 21.1): la menor perturbación de $s = 0,05$ produce imágenes más cercanas a la distribución real y permite al clasificador aprender representaciones transferibles al test set.

Tabla III
RESULTADOS EN ESCENARIOS EXCLUSIVAMENTE SINTÉTICOS (TEST SET 100 % REAL). EN NEGRITA EL MEJOR VALOR POR COLUMNA.

Escenario	AUC	Recall	Prec.	F1	Acc.
Solo TI	0.561	0.000	0.000	0.000	0.862
Solo LoRA	0.551	0.006	0.333	0.012	0.863
Solo GAN	0.610	0.006	0.167	0.012	0.861
Solo Derm $s = 0,40$	0.845	0.145	0.639	0.236	0.873
Solo Derm $s = 0,05$	0.878	0.478	0.576	0.522	0.881

La correlación entre FID y rendimiento en los escenarios exclusivamente sintéticos sugiere que la distancia distribucional entre imágenes sintéticas y reales determina la viabilidad del entrenamiento sin datos reales. El único generador con FID suficientemente bajo (Derm-T2IM $s = 0,05$, FID = 21.1) logra transferir al clasificador conocimiento útil sobre la distribución real del melanoma.

VI. DISCUSIÓN

VI-A. Aumento de datos híbrido

Los cuatro generadores mejoran el AUC del baseline cuando se combinan con datos reales, lo que indica que incluso imágenes sintéticas con alta distancia distribucional (FID = 272.9 en Textual Inversion) aportan información útil cuando coexisten con datos reales en el conjunto de entrenamiento. En este escenario, las imágenes reales actúan como ancla distribucional: el clasificador aprende la distribución del melanoma real y las imágenes sintéticas aportan variabilidad adicional que reduce el sobreajuste a los pocos ejemplos reales de la clase minoritaria.

WGAN-GP logra el mejor AUC híbrido (0.929) pese a tener el tercer peor FID (220.8). Esto muestra que en presencia de datos reales el FID no predice el rendimiento del clasificador. Una posible razón es que las imágenes GAN se generan desde cero, sin partir de una imagen real concreta, por lo que aportan variaciones visuales distintas a las de los métodos imagen-a-imagen; esta mayor diversidad podría favorecer la generalización del clasificador. Sin embargo, el diseño experimental no permite confirmar esta hipótesis de forma aislada.

VI-B. Colapso en entrenamiento exclusivamente sintético

El colapso del clasificador en tres de los cuatro escenarios exclusivamente sintéticos (Recall ≈ 0) tiene una explicación directa en el *domain shift*. Este fenómeno ocurre cuando la distribución de los datos de entrenamiento difiere de la distribución de los datos de prueba: el modelo aprende patrones propios del dominio sintético que no se transfieren al dominio real. En este experimento, cuando el clasificador se entrena exclusivamente con imágenes sintéticas de melanoma, aprende representaciones basadas en los artefactos visuales del generador; al enfrentarse al conjunto de prueba real, esas representaciones no son útiles para discriminar melanoma de nevo. El modelo entonces minimiza la pérdida prediciendo siempre nevo, que constituye el 86.9 % del conjunto de validación, obteniendo accuracy alta con Recall nulo.

Derm-T2IM $s = 0,05$ evita este colapso porque sus imágenes son perturbaciones mínimas de los melanomas reales de entrenamiento, con un FID de 21.1 que refleja una distribución muy cercana a la real. El clasificador entrenado con estas imágenes aprende una representación útil de la clase melanoma que transfiere al test set real. El hecho de que aún así no alcance el desempeño híbrido (AUC = 0.878 frente a 0.917) sugiere que la variabilidad inherente a los datos reales no es totalmente capturada por las perturbaciones mínimas.

VI-C. Efecto del parámetro de fuerza en Derm-T2IM

El parámetro s de Derm-T2IM controla el grado de perturbación aplicado a la imagen de referencia: $s = 0,40$ introduce mayor variación morfológica (FID = 46.7), mientras que $s = 0,05$ produce perturbaciones mínimas (FID = 21.1). Los resultados permiten cuantificar el impacto de este parámetro en ambos tipos de escenario.

En el escenario híbrido, la diferencia entre $s = 0,40$ (Recall = 0.604, AUC = 0.917) y $s = 0,05$ (Recall = 0.610, AUC = 0.920) es marginal: la presencia de datos reales compensa el domain shift adicional de $s = 0,40$ y hace que el beneficio de reducir la perturbación sea casi nulo. En este régimen, la mayor diversidad morfológica de $s = 0,40$ no aporta una ventaja apreciable sobre las perturbaciones mínimas de $s = 0,05$.

En el escenario exclusivamente sintético, el efecto es diferente. $s = 0,40$ obtiene AUC = 0.845 y Recall = 0.145: evita el colapso total (a diferencia de TI, LoRA y GAN), pero el clasificador discrimina deficientemente la clase melanoma. $s = 0,05$, con imágenes más cercanas a la distribución real, alcanza AUC = 0.878 y Recall = 0.478. La diferencia de 25.7 unidades de FID entre ambos se traduce en 33.3 puntos porcentuales de Recall, confirmando que en ausencia de datos reales la proximidad distribucional es el factor crítico.

En conjunto, estos resultados sugieren que s debe calibrarse en función del escenario: en entrenamiento híbrido ambos valores son equivalentes; en entrenamiento exclusivamente sintético, minimizar s (y por tanto el FID) es determinante para la viabilidad del clasificador.

VI-D. Rol del FID como predictor de viabilidad

La relación entre FID y viabilidad del entrenamiento exclusivamente sintético es monotónica en este experimento: el único generador que supera el umbral de viabilidad es el que tiene menor FID. Esto no equivale a afirmar que el FID sea un predictor universal del desempeño del clasificador: en el escenario híbrido la correlación no se mantiene (GAN tiene peor FID que LoRA pero mejor AUC híbrido). El FID es una métrica de distancia distribucional global y no captura propiedades locales de las imágenes que pueden ser relevantes para la tarea de clasificación.

El IS, por su parte, no discrimina entre métodos en este contexto (rango 3.37–3.43). Esto es consistente con la literatura que señala sus limitaciones para detectar *domain shift* y *mode collapse* en datasets especializados.

VI-E. Limitaciones

Las principales limitaciones del estudio son las siguientes. Primero, el volumen fijo de 801 imágenes sintéticas puede no ser óptimo para todos los generadores: no se exploró el impacto de distintos volúmenes de aumento de datos ni la sensibilidad de los resultados a ese hiperparámetro. Segundo, WGAN-GP genera imágenes a 64×64 píxeles que se escalan a 224×224 para la clasificación, lo que introduce un artefacto de resolución que no afecta a los métodos basados en Stable Diffusion. Tercero, los resultados se obtienen con una única

arquitectura de clasificador (EfficientNet-B0) y pueden no generalizar a otros modelos. Cuarto, la evaluación de calidad con FID e IS usa como referencia las imágenes de entrenamiento, no el conjunto completo de melanomas en HAM10000. Quinto, los escenarios Derm-T2IM emplean conjuntos de imágenes generados de forma independiente para cada valor de s (no las mismas muestras), lo que impide una comparación perfectamente controlada del efecto del parámetro sobre el mismo conjunto base. Sexto, tanto FID como IS dependen de características extraídas por InceptionV3, una red entrenada sobre ImageNet, lo que introduce un sesgo hacia imágenes naturales y limita su capacidad para representar adecuadamente dominios especializados como la dermoscopia; métricas complementarias orientadas a modelos generativos, como la Precisión y Recall [17], podrían ofrecer una valoración más robusta.

VII. CONCLUSIONES

Este trabajo evaluó cuatro métodos generativos (Textual Inversion, WGAN-GP, DreamBooth + LoRA y Derm-T2IM) como estrategia de aumento de datos para abordar el desbalanceo de clases en la clasificación binaria nevus/melanoma sobre HAM10000. Los experimentos, controlados por volumen de aumento y con test set siempre 100 % real, permiten extraer tres conclusiones principales.

Primera: el aumento de datos híbrido mejora el Recall de melanoma en todos los generadores respecto al baseline (0.528). Derm-T2IM $s = 0,05$ registra el mayor incremento (+8.2 pp, Recall=0.610), mientras que LoRA obtiene la mayor precisión (0.703) y WGAN-GP el mejor AUC (0.929). Esto indica que incluso imágenes sintéticas de baja fidelidad distribucional son útiles para mejorar la detección de melanoma cuando se combinan con datos reales.

Segunda: el entrenamiento exclusivamente con datos sintéticos provoca que el clasificador no detecte ningún melanoma (Recall ≈ 0) en tres de los cuatro métodos. El *domain shift*, entendido como la diferencia entre la distribución de las imágenes sintéticas y la de las imágenes reales del test set, es el factor determinante: el único generador que mantiene un Recall viable es Derm-T2IM $s = 0,05$ (Recall=0.478, FID=21.1), que produce imágenes significativamente más cercanas a la distribución real.

Tercera: el FID predice correctamente la viabilidad del entrenamiento exclusivamente sintético: a menor FID, mayor Recall. Por otra parte, el IS no discrimina entre generadores en este contexto. El FID es en este estudio, la métrica de calidad generativa más informativa para anticipar el impacto clínico de los datos sintéticos.

Como trabajo futuro se propone explorar la sensibilidad de los resultados al volumen de aumento de datos, aplicar los métodos a otras arquitecturas de clasificador y extender el análisis a escenarios multiclase con las siete categorías de HAM10000. También resulta de interés evaluar si generadores más recientes, como Stable Diffusion XL o modelos de difusión de flujo, reducen el domain shift y habilitan un entrenamiento exclusivamente sintético con Recall clínicamente viable.

REFERENCIAS

- [1] A. Esteva, B. Kuprel, R. A. Novoa, J. Ko, S. M. Swetter, H. M. Blau, and S. Thrun, "Dermatologist-level classification of skin cancer with deep neural networks," *Nature*, vol. 542, pp. 115–118, Feb. 2017.
- [2] M. Tan and Q. V. Le, "EfficientNet: Rethinking model scaling for convolutional neural networks," in *Proc. 36th Int. Conf. Mach. Learn. (ICML)*, 2019, pp. 6105–6114.
- [3] N. V. Chawla, K. W. Bowyer, L. O. Hall, and W. P. Kegelmeyer, "SMOTE: Synthetic minority over-sampling technique," *J. Artif. Intell. Res.*, vol. 16, pp. 321–357, 2002.
- [4] C. Baur, S. Albarqouni, and N. Navab, "MelanoGANs: High resolution skin lesion synthesis with GANs," *arXiv preprint arXiv:1804.04338*, 2018.
- [5] P. Tschandl, "The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions," Harvard DataVerse, 2018. [Online]. Available: <https://doi.org/10.7910/DVN/DBW86T>
- [6] R. Gal *et al.*, "An image is worth one word: Personalizing text-to-image generation using textual inversion," *arXiv preprint arXiv:2208.01618*, 2022.
- [7] N. Ruiz, Y. Li, V. Jampani, Y. Pritch, M. Rubinstein, and K. Aberman, "DreamBooth: Fine tuning text-to-image diffusion models for subject-driven generation," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2023, pp. 22500–22510.
- [8] M. A. Farooq, W. Yao, M. Schukat, M. A. Little, and P. Corcoran, "Derm-T2IM: Harnessing synthetic skin lesion data via Stable Diffusion models for enhanced skin disease classification using ViT and CNN," *arXiv preprint arXiv:2401.05159*, Jan. 2024.
- [9] I. Gulrajani, F. Ahmed, M. Arjovsky, V. Dumoulin, and A. Courville, "Improved training of Wasserstein GANs," *arXiv preprint arXiv:1704.00028*, 2017.
- [10] M. Akrouit *et al.*, "Diffusion-based data augmentation for skin disease classification: Impact across original medical datasets to fully synthetic images," in *Deep Generative Models, MICCAI 2023, Lecture Notes in Computer Science*, vol. 14533, Springer, 2024, pp. 99–109.
- [11] F. Rahat, M. S. Hossain, M. R. Ahmed, S. K. Jha, and R. Ewetz, "Data augmentation for image classification using generative AI," in *Proc. IEEE/CVF Winter Conf. Appl. Comput. Vis. (WACV)*, 2025, pp. 4173–4181.
- [12] Y. Chan, Z. Yan, and Y. Zhu, "A comprehensive survey for generative data augmentation," *arXiv preprint arXiv:2310.00277*, 2023.
- [13] M. Ibrahim *et al.*, "Generative AI for synthetic data across multiple medical modalities: A systematic review of recent developments and challenges," *arXiv preprint arXiv:2407.00116*, 2024.
- [14] L. Zhang *et al.*, "Generative AI enables medical image segmentation in ultra low-data regimes," *Nature Commun.*, vol. 16, art. 6486, Jul. 2025.
- [15] R. Rombach, A. Blattmann, D. Lorenz, P. Esser, and B. Ommer, "High-resolution image synthesis with latent diffusion models," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, 2022, pp. 10684–10695.
- [16] M. Heusel, H. Ramsauer, T. Unterthiner, B. Nessler, and S. Hochreiter, "GANs trained by a two time-scale update rule converge to a local Nash equilibrium," in *Adv. Neural Inf. Process. Syst. (NeurIPS)*, vol. 30, 2017.
- [17] M. Kynkäänniemi, T. Karras, S. Laine, J. Lehtinen, and T. Aila, "Improved precision and recall metric for assessing generative models," in *Adv. Neural Inf. Process. Syst. (NeurIPS)*, vol. 32, 2019, pp. 3927–3936.
- [18] T. Salimans, I. Goodfellow, W. Zaremba, V. Cheung, A. Radford, and X. Chen, "Improved techniques for training GANs," in *Adv. Neural Inf. Process. Syst. (NeurIPS)*, vol. 29, 2016.