Primera entrega

1. **Título del Proyecto:** Generación de datos sintéticos mediante Stable Diffusion para robustecer clasificadores de lesiones cutáneas.

2. **Integrantes del grupo:** Santiago Chica, Gabriel Gómez, Michael Patiño, Juan Diego Sarmiento

3**. Contexto y problema.**

a. Situación Actual: El diagnóstico temprano de enfermedades de la piel es determinante para la supervivencia del paciente. Los modelos de deep learning, han sido herramientas que permiten este dianóstico de forma automatizado. Sin embargo, el entrenamiento de estos modelos requiere grandes volúmenes de datos etiquetados, los cuales son costosos y difíciles de obtener. El dataset HAM10000, contiene 10.000 imágenes dermatoscópicas distribuidas en 7 categorías diagnósticas con un severo desbalance de clases. Los nevos melanocíticos, que son lesiones benignas, concentran ~67% de las muestras, mientras que el melanoma, una forma agresiva y potencialmente mortal de cáncer de piel, representa apenas ~11% del dataset. Este desbalance dificulta que los modelos de clasificación aprendan a detectar correctamente las lesiones malignas.

b. Problema y relevancia: El desbalance de clases provoca que los clasificadores desarrollen un sesgo hacia la clase mayoritaria, reduciendo su sensibilidad frente al melanoma. Las técnicas tradicionales de aumento de datos (rotaciones, flips, cambios de brillo) no introducen nueva información morfológica. Sin embargo, los avances recientes en IA generativa abren nuevas oportunidades mediante LLMs, modelos visión-lenguaje y modelos de síntesis de imágenes [1]. Este proyecto plantea una clasificación binaria (Nevos vs. Melanoma) para evaluar el impacto de datos sintéticos generados con Stable Diffusion sobre el desbalance de clases.

c. Impacto esperado: Se espera que la incorporación de imágenes sintéticas de melanoma permita equilibrar el dataset, mejorando las métricas de clasificación (particularmente recall y F1-score para la clase minoritaria) sin requerir la recolección de nuevas muestras clínicas. Esto podría aplicarse en sistemas automatizados de detección temprana de lesiones cutáneas cuando el número de muestras de entrenamiento es limitado.

4**. Objetivos:**

Objetivo General:

Evaluar el impacto del uso de datos sintéticos generados mediante Stable Diffusion en el desempeño de un modelo de clasificación de lesiones cutáneas, utilizando el dataset HAM10000, con el fin de mitigar el problema de desbalance de clases

Objetivos Específicos.

- Generar nuevas imágenes a partir de descripciones textuales utilizando Stable Diffusion, con el fin de ampliar la diversidad del dataset.
- Analizar la calidad y utilidad de las imágenes sintéticas generadas mediante Stable Diffusion, con las siguientes métricas: Inception Score (IS), Frechet Inception Distance

(FID). Además, validar las imágenes generadas utilizando un clasificador binario (piel vs. no-piel) para descartar artefactos
- Entrenar modelos de clasificación de imágenes utilizando el dataset original, un híbrido de datos sintéticos/reales y solo con datos sintéticos. Comparar el desempeño de los modelos mediante métricas: recall y F1-score para la clase minoritaria.

5. Estado del arte.

Paper [1] - *Data Augmentation for Image Classification using Generative AI:* El paper enfatiza en que el rendimiento de los modelos de deep learning suele depender de la cantidad y diversidad de datos disponibles para el entrenamiento. Sin embargo, en muchos dominios, como la identificación de especies animales o aves, la recolección de grandes conjuntos de datos etiquetados resulta costosa y difícil. En este contexto, la aumentacion de data es una gran solucion, alternativa o estrategia para ampliar artificialmente los datasets.

Los métodos tradicionales de aumento de datos, como rotaciones, traslaciones, recortes y cambios de escala, pueden generar nuevas muestras, pero esta estrategia introducen distorsiones en el objeto de interés o artefactos irrelevantes. En los ultimos avances, modelos generativos basados en Large Language Models, Vision-Language Models y modelos de difusión han demostrado ser efectivos para generar imágenes sintéticas mediante técnicas como text-to-image, image-to-image e image inpainting. No obstante, estos enfoques suelen requerir fine-tuning, lo que implica alta complejidad computacional y la necesidad de repetir el proceso para cada nuevo dataset.

Para enfrentar estas limitaciones, el paper propone Automated Generative Data Augmentation (AGA), un framework que combina modelos de segmentación (para el objeto de interés), modelos de lenguaje y modelos de difusión para generar automáticamente nuevas imágenes de entrenamiento. El método AGA preserva el objeto de interés en primer plano mientras introduce diversidad en el fondo de la imagen. AGA se basa en tres componentes principales: extracción del objeto mediante segmentación, generación automática de prompts con diversidad combinatoria y manipulación afín del sujeto.

Paper [2] - *Diffusion-based Data Augmentation for Skin Disease Classification: Impact Across Original Medical Datasets to Fully Synthetic Images:* El paper aborda la limitación de datos etiquetados en aplicaciones médicas, donde las políticas de privacidad y las restricciones de acceso dificultan la construcción de datasets grandes y diversos. En este contexto, los modelos de difusión probabilística (DPMs) han surgido como una alternativa superior a GANs y autoencoders variacionales para generar imágenes sintéticas de alta calidad.

Los autores proponen un pipeline de aumento de datos basado en Stable Diffusion, aplicado a la clasificación de seis enfermedades cutáneas (incluyendo melanoma y carcinoma basocelular). El proceso consiste en aprender embeddings específicos para cada enfermedad mediante textual inversion, generar imágenes sintéticas condicionadas por text prompts, y curar las imágenes generadas mediante un filtro binario (piel vs. no-piel)

seguido de un clasificador ensemble preentrenado que verifica la etiqueta de la enfermedad.

Los experimentos comparan clasificadores entrenados bajo cuatro escenarios: solo datos reales, dataset reducido, dataset híbrido (50% real, 50% sintético) y dataset completamente sintético. Los resultados muestran que el dataset híbrido mantiene una accuracy comparable al dataset real completo, y que incluso el dataset 100% sintético logra resultados cercanos, lo que sugiere que los modelos de difusión pueden ser una herramienta viable para compartir datos médicos sin comprometer la privacidad.

Paper [3] - *A Comprehensive Survey for Generative Data Augmentation:* Este paper habla de la necesidad de nuevas formas de conseguir datos de entrenamiento para modelos de inteligencia artificial. Estos modelos dependen de datos de calidad lo cual a su vez requiere el uso de herramientas avanzadas como sensores precisos, equipos electrónicos sofisticados, expertos en el área para la evaluación y etiquetado de datos. A causa de esto, la adquisición de datos puede ser lento y costoso y puede considerarse como un cuello de botella dentro del proceso de entrenamiento de modelos de aprendizaje automático. Por esta razón es indispensable idear maneras más asequibles que puedan asistir el entrenamiento de dichos modelos.

Para esto, hace una revisión del estado del arte de modelos generativos como variational auto encoders (VAE), generative adversal networks (GAN) y generative pre-trained transformers (GPT), sus fortalezas y limitaciones; y técnicas de evaluación para la aumentación de datos generativos. Finalmente, propone una metodología para aprovechar el potencial de la IA generativa para mejorar el desempeño de modelos al aplicar pequeñas variaciones en los datos y reforzar los datos de entrenamiento para una mejor generalización.

Paper [4] - *Generative AI for Synthetic Data Across Multiple Medical Modalities:* Este paper [4] realiza una revisión exhaustiva del aumento de datos por IA generativa en múltiples modalidades médicas. Especialmente, destaca el éxito que ha tenido el aumento datos generativos en múltiples modalidades médicas tales como Historia Clínica Electrónica (EHR), señales de series de tiempo, texto medico como generación de resumen, e imagenología que van desde dermatología hasta rayos X y MRI. Dentro de esta última, es especialmente relevante los resultados que ha generado debido a la generación de imágenes dentro de problemas dermatológicos usando modelos generativos con GANs y modelos de difusión como PGGAN y DALL.E-2. Estos modelos fueron capaces de mejorar la habilidad de los modelos de clasificación de aprender detalles y patrones más complejos en base los datos, especialmente los poco representados, una situación común que ocurre cuando existe desbalance de clases en el dataset de entrenamiento, llegando a superar técnicas tradicionales como desplazamiento, recorte o zoom durante la etapa de evaluación en métricas como accuracy.

Paper [5] - Generative AI enables medical image segmentation in ultra low-data regimes: El paper aborda la segmentación semántica de imágenes médicas cuando hay muy pocos datos etiquetados. Anotar máscaras a nivel de píxel es costoso y requiere experiencia

clínica, lo que limita los datos disponibles. Las estrategias existentes tratan la generación de datos y el entrenamiento como procesos separados, produciendo datos sintéticos que no necesariamente mejoran el modelo downstream.

Los autores proponen GenSeg, un framework end-to-end que genera pares de imágenes y máscaras mediante optimización multi-nivel, donde el rendimiento del modelo de segmentación guía directamente la generación. El proceso usa un mecanismo de generación inversa: parte de una máscara de segmentación real, le aplica aumentos geométricos básicos para crear una máscara aumentada, y luego un modelo generativo (cuya arquitectura se aprende automáticamente de los datos) sintetiza la imagen médica correspondiente a esa máscara. No requiere imágenes adicionales sin etiquetar y es agnóstico al modelo utilizado.

Fue validado en 11 tareas y 19 datasets con mejoras absolutas de 10–20% en rendimiento, requiriendo entre 8 y 20 veces menos datos etiquetados que los enfoques existentes.

6. Metodología y enfoque propuesto.

Enfoque técnico. La solución se desarrolla en cuatro fases (ver Anexo 1). Primero, se filtra el dataset HAM10000 para obtener un subconjunto binario (Nevos vs. Melanoma) y se divide en conjuntos de entrenamiento, validación y test. Segundo, se realiza fine-tuning de Stable Diffusion mediante textual inversion sobre las imágenes de melanoma para aprender un embedding específico de esta clase y generar imágenes sintéticas. Tercero, se validan las imágenes generadas utilizando un clasificador binario (piel vs. no-piel) para descartar artefactos, y se reportan métricas de calidad generativa (FID e IS). Cuarto, se entrenan clasificadores CNN (EfficientNet y/o ResNet) bajo tres escenarios: solo datos reales, datos híbridos (reales + sintéticos) y solo datos sintéticos, comparando su rendimiento mediante accuracy, F1-score, recall y AUC.

Herramientas: Python, PyTorch, Hugging Face Diffusers (Stable Diffusion), torchmetrics (FID/IS), torchvision (EfficientNet, ResNet), GPU con 16–24 GB vRAM.

7. Exploración y descripción de los datos.

El dataset HAM10000 [6] contiene 10,015 imágenes dermatoscópicas de 7,470 lesiones únicas, lo que implica que hay múltiples imágenes por lesión (promedio de 1.34 y máximo de seis) y un riesgo de data leakage si no se particiona adecuadamente. Las imágenes tienen resolución de 600×450 píxeles en RGB y cuentan con máscaras de segmentación binaria para el 100% del conjunto. El dataset presenta 7 clases diagnósticas con un desbalance marcado: los nevos melanocíticos representan el 66.95%, mientras que clases como dermatofibroma y lesiones vasculares no alcanzan el 2%, con una razón de desbalance cercana a 58:1. Aproximadamente el 53% de los diagnósticos están confirmados por histopatología y el resto por seguimiento clínico o consenso de expertos, lo que introduce distintos niveles de incertidumbre en las etiquetas. El conjunto abarca pacientes entre 0 y 85 años con distribución de sexo equilibrada. La heterogeneidad en iluminación, contraste y artefactos entre instituciones requiere estrategias de normalización y aumento de datos. Para un análisis más detallado, dirigirse al notebook HAM10000_EDA.ipynb.

8. Bibliografía.

[1] F. Rahat, M. S. Hossain, M. R. Ahmed, S. K. Jha, and R. Ewetz, "Data augmentation for image classification using generative AI," in Proc. IEEE/CVF Winter Conf. Appl. Comput. Vis. (WACV), 2025, pp. 4173–4181.

[2] M. Akrout et al., "Diffusion-based data augmentation for skin disease classification: Impact across original medical datasets to fully synthetic images," in Deep Generative Models, MICCAI 2023, Lecture Notes in Computer Science, vol. 14533, Springer, 2024, pp. 99–109.

[3] Chan, Y. Yan, Z. Zhu, Y. “A Comprehensive Survey for Generative Data Augmentation”. 2023. arXiv preprint. arXiv:2310.00277

[4] Ibrahim, M. et al. “Generative AI for Synthetic Data Across Multiple Medical Modalities: A Systematic Review of Recent Developments and Challenges” 2024. ArXiv preprint. ArXiv: 2407.00116.

[5] L. Zhang, B. Jindal, A. Alaa, R. Weinreb, D. Wilson, E. Segal, J. Zou, and P. Xie, "Generative AI enables medical image segmentation in ultra low-data regimes," Nature Commun., vol. 16, art. 6486, Jul. 2025.

[6] Tschandl, P. The HAM10000 dataset, a large collection of multi-source dermatoscopic images of common pigmented skin lesions.Harvard Dataverse https://doi.org/10.7910/DVN/DBW86T (2018)

ANEXO 1.

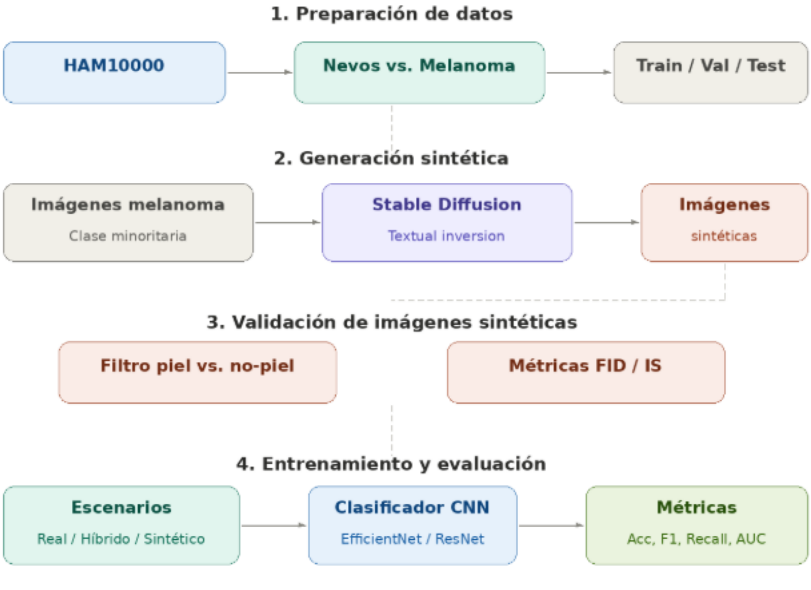

Pipeline propuesto para abordar el problema.